

TP Master IA

Comparaison d'algorithmes d'apprentissage non supervisé

1. Objectif du TP

L'objectif de ce TP est de :

- Mettre en œuvre plusieurs algorithmes d'apprentissage non supervisé
- Comparer leurs performances sur un même jeu de données
- Comprendre la structure cachée des données
- Évaluer la qualité des regroupements sans labels
- Développer une capacité d'analyse critique des résultats

2. Travail demandé

2.1 Compréhension des données

Choisir un dataset (avec ou sans labels, les labels ne doivent pas être utilisés pour l'apprentissage).

À faire :

- Identifier :
 - o Les variables (features)
- Déterminer les types de variables :
 - o Numériques (discrètes / continues)
 - o Catégorielles (nominales / ordinales)
- Analyse exploratoire :
 - o Statistiques descriptives (moyenne, variance, etc.)
 - o Visualisations :
 - Histogrammes
 - Boxplots

- Matrice de corrélation
- Scatter plots

☞ Objectif : comprendre la structure et la distribution des données

2.2 Prétraitement des données

a) Gestion des valeurs manquantes

- Suppression
- Imputation :
 - o Moyenne / médiane
 - o Mode
 - o KNN Imputer (option avancée)

b) Encodage des variables catégorielles

- Label Encoding
- One-Hot Encoding

c) Normalisation / Standardisation

- Min-Max Scaling
- StandardScaler

☞ Très important pour :

- K-Means
- DBSCAN
- PCA

d) Traitement des valeurs aberrantes (outliers)

- Z-score
- IQR
- Isolation Forest (option avancée)

2.3 Modèles à implémenter

◆ *Clustering (regroupement)*

- K-Means
- DBSCAN
- Agglomerative Clustering (hiérarchique)
- Mean Shift (optionnel)
- Gaussian Mixture Models (GMM)

◆ *Réduction de dimension*

- PCA (Principal Component Analysis)
- t-SNE (visualisation)
- UMAP (option avancée)

2.4 Évaluation des modèles

⚠ Pas de variable cible → évaluation interne

◆ *Métriques de clustering*

- Silhouette Score
- Davies-Bouldin Index
- Calinski-Harabasz Index

🔍 Interprétation attendue :

- Cohésion intra-cluster (points proches)
- Séparation inter-cluster (clusters distincts)

◆ *Si labels disponibles (optionnel pour validation)*

- Adjusted Rand Index (ARI)
- Normalized Mutual Information (NMI)

◆ *Évaluation visuelle*

- Projection 2D (PCA / t-SNE)
- Visualisation des clusters

☞ Objectif : vérifier si les groupes sont cohérents visuellement

2.5 Analyse des résultats

À faire :

- Comparer les performances des algorithmes
- Identifier :
 - o Le meilleur clustering
 - o Le modèle le plus stable
- Analyser :
 - o Sensibilité aux paramètres (ex : k pour K-Means, eps pour DBSCAN)
 - o Impact du prétraitement

Questions à traiter :

- Pourquoi certains algorithmes fonctionnent mieux ?
- Quel modèle est le plus robuste au bruit ?
- DBSCAN détecte-t-il mieux les outliers ?
- Le scaling influence-t-il les résultats ?
- Comment choisir le nombre optimal de clusters (méthode du coude, silhouette) ?
- Les clusters sont-ils interprétables ?

3. Structure du rapport (Article scientifique)

◆ Abstract

Résumé (objectif + résultats principaux)

✦ Introduction

- Contexte
- Importance du clustering / exploration des données

✦ État de l'art

- Les travaux ayant traité la même idée
- Présentation des algorithmes
- Avantages / inconvénients

✦ Méthodologie

- Dataset
- Prétraitement
- Choix des modèles

✦ Application

- Implémentation
- Outils (Python, sklearn...)

✦ Résultats & Discussion

- Tableaux comparatifs
- Visualisations
- Analyse critique

✦ Conclusion

- Résumé
- Perspectives

✦ Références

5. Contraintes

- Travail individuel
- Justification obligatoire des choix
- L'utilisation d'IA est non permise

6. Bonus avancé (fortement recommandé)

◆ Optimisation des modèles

- Méthode du coude (Elbow Method)
- Silhouette Analysis

◆ Clustering avancé

- Spectral Clustering
- HDBSCAN

◆ Interprétation

- Analyse des centroïdes (K-Means)
- Importance des variables dans PCA

◆ Robustesse

- Sensibilité aux outliers
- Test avec bruit

◆ Visualisation avancée

- t-SNE / UMAP
- Projection interactive

◆ Analyse approfondie

- Stabilité des clusters
- Comparaison multi-initialisations
- Analyse de la densité (DBSCAN)